Université Hassan 1er

ÉCOLE NATIONALE DE COMMERCE ET DE GESTION DE SETTAT

COMPTE RENDU DE PROJET

Algorithmes de Clustering

Étude comparative avec données réelles (scikit-learn)

Module : Intelligence Artificielle & Apprentissage Automatique

Filière : CAC / Commerce International / PSCM — L3 S8

Réalisé par : Liousfi Marwa et Siham Mahboub

Encadrant : Larhimli Abderahman

Période : Mars 2026

Année Universitaire 2025–2026

I. INTRODUCTION

I.1 Contexte et problématique

Dans le cadre du module d'Intelligence Artificielle et d'Apprentissage Automatique, ce travail porte sur l'étude comparative des principaux algorithmes de clustering, ou classification non supervisée. Cette famille de méthodes vise à regrouper automatiquement des observations similaires sans recourir à des étiquettes prédéfinies, ce qui la distingue fondamentalement de l'apprentissage supervisé.

La problématique centrale de ce rapport est la suivante : étant donné la diversité des algorithmes de clustering disponibles, comment choisir la méthode la plus adaptée à une situation donnée ? Cette question revêt une importance pratique considérable dans des domaines tels que la segmentation de clientèle, la détection d'anomalies, l'analyse d'images ou encore la bio-informatique.

I.2 Objectifs du travail

Le présent compte rendu poursuit trois objectifs complémentaires. Il s'agit d'abord d'exposer les fondements théoriques de chaque algorithme étudié, en mettant en évidence les hypothèses sous-jacentes et les paramètres clés. Il convient ensuite d'illustrer leur fonctionnement par une implémentation pratique en Python (bibliothèque scikit-learn), appliquée à des jeux de données réels. Enfin, une comparaison systématique des performances est conduite afin de formuler des recommandations d'usage.

I.3 Méthodologie adoptée

L'analyse repose sur quatre jeux de données de référence : Iris (150 observations, 4 variables), Wine (178 observations, 13 variables), Digits (1 797 observations, 64 variables) et des données synthétiques de forme non-convexe (Moons, Circles). Avant toute modélisation, une étape de normalisation (StandardScaler) et de réduction dimensionnelle (ACP à 2 composantes) est systématiquement appliquée pour assurer la comparabilité des résultats.

Les performances sont évaluées principalement à l'aide du score de silhouette, qui mesure la cohésion intra-cluster et la séparation inter-cluster sur un intervalle [-1, 1]. Des critères complémentaires sont mobilisés selon les algorithmes : inertie (K-Means), critères BIC/AIC (GMM) et taux de détection du bruit (algorithmes à densité).

II. PRÉPARATION DES DONNÉES

II.1 Normalisation et réduction de dimension

La normalisation constitue un préalable indispensable à l'application de tout algorithme de clustering. En l'absence de cette étape, les variables à grande amplitude numérique domineraient artificiellement le calcul des distances. La transformation StandardScaler ramène chaque variable à une distribution de moyenne nulle et d'écart-type unitaire.

La réduction à deux dimensions par Analyse en Composantes Principales (ACP) sert exclusivement à la visualisation des résultats. Il est important de noter qu'un objet ACP distinct est instancié pour chaque jeu de données, les dimensions originales étant hétérogènes (4, 13 et 64 variables respectivement). La projection des centroïdes ou médoïdes dans l'espace réduit est réalisée via la méthode transform() de l'objet ACP préalablement ajusté.

II.2 Métriques d'évaluation

Trois métriques principales sont mobilisées dans ce travail. Le score de silhouette évalue la qualité de tout clustering en mesurant, pour chaque point, le rapport entre sa distance aux autres membres de son cluster et sa distance au cluster le plus proche. Une valeur proche de 1 indique des clusters bien séparés et denses. L'inertie (ou WCSS) mesure la somme des carrés des distances des points à leur centroïde et s'applique spécifiquement au K-Means. Les critères BIC et AIC permettent de sélectionner le nombre optimal de composantes dans les modèles de mélange gaussien, en pénalisant la complexité du modèle.

Métrique	Description	Interprétation
Score de silhouette	Cohésion intra-cluster vs séparation inter-cluster	[-1, 1] — valeur proche de 1 = meilleur
WCSS / Inertie	Somme des distances au centroïde (K-Means)	À minimiser
BIC / AIC	Critères de sélection de modèle (GMM)	À minimiser

III. ALGORITHMES PARTITIONNELS

III.1 K-Means

Principe théorique

K-Means est l'algorithme de clustering le plus répandu. Il partitionne les données en k clusters en minimisant la somme des variances intra-cluster (WCSS — Within-Cluster Sum of Squares). L'algorithme de Lloyd, utilisé par défaut, procède en quatre étapes itératives : initialisation des k centroïdes (méthode k-means++ par défaut), affectation de chaque point au centroïde le plus proche, recalcul des centroïdes comme moyennes des points affectés, puis répétition jusqu'à convergence.

La complexité algorithmique est de l'ordre $O(n \times k \times t \times d)$, où n désigne le nombre d'observations, k le nombre de clusters, t le nombre d'itérations et d le nombre de dimensions. Cet algorithme repose sur des hypothèses fortes : les clusters doivent être convexes, isotropes et de taille comparable.

Hyperparamètre	Rôle
n_clusters	Nombre de clusters (à spécifier a priori)
n_init	Nombre de réinitialisations aléatoires (défaut : 10)
random_state	Graine pour la reproductibilité

Résultats obtenus (Dataset Iris)

Métrique	Valeur
Score de silhouette	≈ 0,46
WCSS (k = 3)	≈ 139
Clusters identifiés	3

> ***Remarque :*** *La courbe Elbow présente un coude bien marqué à k = 3, cohérent avec les 3 espèces d'iris du jeu de données. Cette méthode de sélection du k optimal est recommandée lorsqu'aucune connaissance a priori n'est disponible.*

III.2 K-Medoids (PAM)

Principe théorique

K-Medoids constitue une variante robuste de K-Means dans laquelle les représentants de cluster (médoïdes) sont des points réels du jeu de données et non des moyennes. L'algorithme PAM (Partitioning Around Medoids) minimise la somme des distances L1 (Manhattan) entre chaque point et le médoïde de son cluster. Cette propriété confère à l'algorithme une robustesse accrue face aux valeurs aberrantes, car un outlier ne peut être sélectionné comme médoïde s'il accroît significativement le coût

global.

Critère	K-Means	K-Medoids
Centroïde	Moyenne des points (virtuel)	Point réel du dataset
Sensibilité aux outliers	Élevée	Faible
Distance utilisée	Euclidienne	Toute métrique (L1, etc.)
Complexité	$O(n \times k \times t)$	$O(k \times (n-k)^2)$ par itération

> ***Remarque :*** *Sur le dataset Iris (données propres, peu d'outliers), K-Medoids obtient un score de silhouette de ≈ 0,46, très proche de K-Means. La différence se manifeste davantage sur des données bruitées.*

III.3 K-Medians

K-Medians remplace le calcul de la moyenne par la médiane pour la mise à jour des centres de cluster. La propriété statistique de résistance de la médiane la rend intrinsèquement plus robuste face aux valeurs extrêmes que la moyenne. La distance minimisée est la norme L1 (Manhattan). L'implémentation proposée est réalisée manuellement en NumPy, cet algorithme n'étant pas inclus dans scikit-learn. Sur Iris, un score de silhouette de ≈ 0,45 est obtenu, résultat similaire au K-Means en raison de la propreté du jeu de données.

IV. ALGORITHMES BASÉS SUR LA DENSITÉ

IV.1 DBSCAN

Principe théorique

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) identifie les clusters comme des régions denses séparées par des zones creuses. L'algorithme introduit trois catégories de points : les points cœur (qui disposent d'au moins MinPts voisins dans un rayon ε), les points frontière (situés dans le voisinage d'un point cœur sans en être un eux-mêmes), et les points de bruit (étiquetés -1), qui n'appartiennent à aucun cluster.

L'atout majeur de DBSCAN réside dans sa capacité à détecter des clusters de forme arbitraire (spirales, croissants) là où K-Means échoue, tout en identifiant automatiquement les outliers. Il ne requiert pas la spécification a priori du nombre k.

Dataset	ε	Clusters détectés	Points de bruit
Moons (synthétique)	0,2	2	0
Circles (synthétique)	0,2	2	0
Iris (normalisé)	0,5	2–3	≈ 5

IV.2 HDBSCAN

HDBSCAN (Hierarchical DBSCAN) étend DBSCAN en construisant une hiérarchie de densité plutôt qu'en utilisant un seuil ε fixe. L'algorithme calcule les distances core mutuellement atteignables, construit un arbre couvrant minimal sur ce graphe, condense la hiérarchie en arbre de clusters, puis extrait les clusters les plus stables — c'est-à-dire ceux qui persistent le plus longtemps dans la hiérarchie. Il fournit de surcroît une probabilité d'appartenance pour chaque point, permettant de quantifier la confiance de l'affectation. Le principal avantage sur DBSCAN est la robustesse aux clusters de densités variables.

IV.3 OPTICS

OPTICS (Ordering Points To Identify the Clustering Structure) généralise DBSCAN pour traiter des clusters de densités variables. Il produit un reachability plot dans lequel les vallées correspondent aux clusters : plus une vallée est profonde, plus le cluster associé est dense. Contrairement à DBSCAN, OPTICS ne requiert pas de seuil ε précis et révèle la structure hiérarchique des données. Sur Iris, le reachability plot met en évidence 2 à 3 vallées distinctes correspondant aux espèces.

V. CLUSTERING HIÉRARCHIQUE AGGLOMÉRATIF (HAC)

V.1 Principe théorique

Le clustering hiérarchique agglomératif (HAC) construit une arborescence de clusters — appelée dendrogramme — en fusionnant successivement les paires les plus proches, du bas vers le haut. L'algorithme part d'un état où chaque observation constitue son propre cluster, puis fusionne itérativement les deux clusters les plus proches jusqu'à n'en former plus qu'un seul. La partition finale est obtenue en coupant le dendrogramme à la hauteur souhaitée.

Quatre méthodes de liaison (linkage) sont disponibles, chacune définissant

différemment la distance entre deux clusters. La méthode Ward minimise l'accroissement de variance intra-cluster lors de chaque fusion et produit en général les clusters les plus équilibrés. La méthode single est sensible à l'effet de chaînage (chaining) qui peut déformer la structure des clusters.

V.2 Résultats comparatifs (Dataset Iris)

Méthode de liaison	Score de silhouette	Observation
Ward	≈ 0,48	Meilleure performance — clusters équilibrés
Average	≈ 0,47	Bon compromis
Complete	≈ 0,45	Clusters compacts
Single	≈ 0,22	Sensible à l'effet de chaînage

VI. MODÈLES DE MÉLANGE GAUSSIEN (GMM)

VI.1 Principe théorique

Les modèles de mélange gaussien (GMM) modélisent les données comme une superposition pondérée de k distributions gaussiennes. Contrairement aux algorithmes précédents, le GMM réalise un clustering mou (soft clustering) : chaque observation appartient à chaque cluster avec une certaine probabilité. Les paramètres du modèle (poids, moyennes, matrices de covariance) sont estimés par l'algorithme EM (Expectation-Maximization), qui alterne entre une étape E de calcul des probabilités a posteriori et une étape M de maximisation de la vraisemblance.

Quatre types de matrices de covariance sont disponibles, correspondant à des géométries de clusters différentes. La covariance full (matrice complète propre à chaque composante) offre la plus grande flexibilité mais requiert davantage de données. Le type spherical impose des clusters sphériques de tailles variables, se rapprochant ainsi du K-Means.

VI.2 Résultats (Dataset Wine)

Type de covariance	Silhouette	BIC
full	≈ 0,28	Le plus faible (recommandé)
tied	≈ 0,27	Intermédiaire
diag	≈ 0,26	Intermédiaire
spherical	≈ 0,15	Le plus élevé

> ***Remarque :*** *Le critère BIC identifie correctement k = 3 pour le dataset Wine, en accord avec les 3 types de vins effectivement présents dans le jeu de données.*

VII. MÉTHODES AVANCÉES

VII.1 Spectral Clustering

Le Spectral Clustering exploite la structure spectrale (valeurs et vecteurs propres) du graphe de similarité pour réaliser une réduction dimensionnelle, avant d'appliquer K-Means dans l'espace réduit. Cette approche en deux temps lui permet de détecter des clusters de forme non-convexe (cercles concentriques, spirales) là où K-Means échoue systématiquement. Sur le dataset Circles, Spectral Clustering sépare parfaitement les deux cercles concentriques avec un score de silhouette de ≈ 0,45 sur Iris.

VII.2 Affinity Propagation

Affinity Propagation détermine automatiquement le nombre de clusters en faisant passer des messages de responsabilité et de disponibilité entre tous les couples de points. Chaque point peut devenir l'exemplaire (représentant) de son cluster. L'avantage principal est l'absence de spécification de k, mais l'algorithme tend à sur-segmenter les données : sur Iris, il détecte 7 à 9 clusters au lieu des 3 réels. Le paramètre damping (facteur d'amortissement) permet de stabiliser la convergence.

Avantage	Inconvénient
k déterminé automatiquement	Complexité $O(n^2)$ — plus lent
Pas d'initialisation aléatoire	Tendance à créer trop de clusters
Exemplaires = points réels	Sensible au paramètre damping

VII.3 Self-Organizing Maps (SOM)

Les cartes auto-organisatrices (SOM) constituent un réseau de neurones non supervisé qui projette des données de haute dimension sur une grille bidimensionnelle en préservant la topologie. Chaque neurone de la grille N×N possède un vecteur de poids dans l'espace original. L'apprentissage procède en identifiant pour chaque observation le neurone le plus proche (Best Matching Unit, BMU), puis en mettant à jour ce neurone et ses voisins par une règle d'adaptation à taux décroissant.

La U-Matrix (Unified Distance Matrix) visualise les distances moyennes entre

neurones voisins : les zones sombres représentent des frontières entre clusters. Sur Wine (grille 7×7), la U-Matrix révèle clairement 3 régions distinctes correspondant aux 3 types de vins.

VII.4 UMAP + K-Means

UMAP (Uniform Manifold Approximation and Projection) est un algorithme de réduction dimensionnelle non-linéaire qui préserve à la fois la structure locale et la structure globale des données. Il surpasse t-SNE en termes de vitesse et de reproductibilité. Le pipeline proposé réduit les 64 dimensions du dataset Digits à 2, puis applique K-Means sur l'espace UMAP — beaucoup plus séparable que l'espace original.

Espace d'évaluation	Score de silhouette
Espace original (64 dimensions)	≈ 0,15–0,20
Espace UMAP (2 dimensions)	≈ 0,60–0,70

VIII. RÉSULTATS ET DISCUSSION

VIII.1 Tableau comparatif global (Dataset Iris normalisé)

Algorithme	k détecté	Silhouette	Remarque principale
K-Means	3	≈ 0,46	Référence — clusters sphériques
K-Medoids	3	≈ 0,46	Robuste aux outliers
K-Medians	3	≈ 0,45	Robuste — implémentation manuelle
HAC Ward	3	≈ 0,48	Meilleur score sur Iris
GMM full	3	≈ 0,28	Clustering probabiliste (mou)
Spectral	3	≈ 0,45	Efficace pour formes non-convexes
DBSCAN	2–3	≈ 0,50	Détection automatique du bruit
OPTICS	2–3	≈ 0,40	Densités variables
Affinity Prop.	7–9	≈ 0,45	k automatique — sur-segmentation

VIII.2 Interprétation et analyse critique

L'analyse comparative révèle que la méthode HAC avec liaison Ward obtient le meilleur score de silhouette sur Iris (≈ 0,48), suivie par DBSCAN (≈ 0,50 sur données avec bruit). Ces résultats s'expliquent par la structure du jeu de données : Iris présente

des clusters relativement bien séparés et de forme quasi-sphérique, ce qui favorise les méthodes hiérarchiques et partitionnelles.

Le score plus faible de GMM (≈ 0,28) ne constitue pas une indication de mauvaise performance, mais reflète la nature probabiliste de ce modèle : le clustering mou produit des frontières plus diffuses, ce qui pénalise mécaniquement le score de silhouette. Sur des données véritablement gaussiennes, GMM surpasse souvent K-Means.

La sur-segmentation observée avec Affinity Propagation (7 à 9 clusters au lieu de 3) illustre une limite bien connue de cet algorithme : son comportement est sensible au choix du paramètre damping et à la valeur des préférences initiales. Il est particulièrement adapté aux situations où k est réellement inconnu et où la précision de la segmentation prime sur le nombre de clusters.

VIII.3 Limites et axes d'amélioration

Plusieurs limites méritent d'être soulignées. D'une part, l'évaluation par le score de silhouette ne capture pas tous les aspects de la qualité d'un clustering : deux partitions de scores similaires peuvent correspondre à des structures très différentes. D'autre part, les hyperparamètres utilisés (ε pour DBSCAN, damping pour AP, etc.) ont été fixés manuellement ; une approche automatique de sélection serait souhaitable.

Des pistes d'amélioration incluent l'application de méthodes d'optimisation des hyperparamètres (grid search, optimisation bayésienne), l'évaluation sur des jeux de données plus complexes et de plus grande dimension, ainsi que l'intégration de mesures de validation interne complémentaires (Davies-Bouldin, Calinski-Harabasz).

IX. SYNTHÈSE DES CHOIX ALGORITHMIQUES

IX.1 Guide de sélection

La sélection d'un algorithme de clustering doit s'appuyer sur une analyse préalable des caractéristiques du problème : connaissance a priori de k, forme supposée des clusters, présence de bruit, et dimension des données. Le tableau suivant synthétise les recommandations issues de cette étude comparative.

Situation	Algorithme recommandé
k connu, clusters sphériques	K-Means
k connu, robustesse aux outliers	K-Medoids

Situation	Algorithme recommandé
k connu, distribution gaussienne	GMM
k connu, forme quelconque	Spectral Clustering
k inconnu, détection du bruit	DBSCAN / HDBSCAN
k inconnu, densités variables	OPTICS / HDBSCAN
k inconnu, pas de contrainte	Affinity Propagation
Haute dimension + visualisation	UMAP + K-Means
Données catégorielles / mixtes	K-Medoids

IX.2 Dépendances et environnement technique

L'ensemble des implémentations repose sur l'écosystème Python scientifique. Les bibliothèques standard (scikit-learn, NumPy, Matplotlib) couvrent K-Means, DBSCAN, OPTICS, HAC, GMM, Spectral Clustering et Affinity Propagation. Des bibliothèques complémentaires sont nécessaires pour K-Medoids (scikit-learn-extra), HDBSCAN, les Self-Organizing Maps (minisom) et UMAP (umap-learn).

X. CONCLUSION

Ce compte rendu a permis d'explorer de manière systématique onze algorithmes de clustering représentatifs, couvrant les approches partitionnelles, à densité, hiérarchiques, probabilistes et spectrales. L'analyse comparative conduite sur des jeux de données réels de référence confirme qu'il n'existe pas d'algorithme universellement optimal : chaque méthode présente des hypothèses sous-jacentes et des domaines d'application qui lui sont propres.

Les algorithmes partitionnels (K-Means, K-Medoids, K-Medians) offrent un bon compromis entre performance et interprétabilité pour des clusters de forme convexe. Les méthodes à densité (DBSCAN, HDBSCAN, OPTICS) se distinguent par leur capacité à détecter des formes arbitraires et à identifier le bruit. Le clustering hiérarchique et le Spectral Clustering enrichissent l'arsenal pour les structures complexes, tandis que GMM apporte une perspective probabiliste précieuse. Enfin, UMAP combiné à K-Means s'impose comme la référence pour les données de haute dimension.

Cette étude ouvre plusieurs perspectives : l'évaluation sur des données réelles de

gestion (segmentation de clientèle, analyse de portefeuille), l'exploration de méthodes hybrides, et l'intégration de ces techniques dans des pipelines d'apprentissage automatique complets. La maîtrise du clustering constitue en effet un prérequis fondamental pour l'analyse exploratoire des données dans tout contexte professionnel ou académique.

BIBLIOGRAPHIE / WEBOGRAPHIE

Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. KDD, 96(34), 226–231.

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

McInnes, L., Healy, J., & Melville, J. (2018). UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. arXiv:1802.03426.

Kohonen, T. (2001). Self-Organizing Maps (3e éd.). Springer.

Documentation scikit-learn. Clustering. Disponible sur : https://scikit-learn.org/stable/modules/clustering.html

Documentation UMAP. Disponible sur : https://umap-learn.readthedocs.io/