

COMPTE RENDU DE PROJET — S8

Détection de Fraude dans la Consommation d'Énergie

Compétition Zindi — STEG (Société Tunisienne de l'Électricité et du Gaz)

Module :	Machine Learning & Data Science
Filière :	CAC / Commerce International / PSCM — L3 S8
Réalisé par :	Siham MAHBOUB et Marwa LIOUSFI
Encadrant :	Abderahman Larhimli
Période :	Année Universitaire 2026–2027

Année Universitaire 2026–2027

SOMMAIRE

I.	INTRODUCTION	3
I.1	Présentation de l'organisme	3
I.2	Contexte et problématique	3
I.3	Objectifs du projet	4
II.	PRÉSENTATION DES DONNÉES ET DU DATASET	4
II.1	Description des fichiers de données	4
II.2	Variables du dataset clients	5
II.3	Variables du dataset factures	5
III.	DÉVELOPPEMENT	5
III.1	Analyse exploratoire des données (EDA)	5
III.2	Préparation et prétraitement des données	6
III.3	Modèles testés et méthodes d'apprentissage	7
III.4	Modèle retenu : XGBoost optimisé	8
IV.	RÉSULTATS ET DISCUSSION	9
IV.1	Métriques d'évaluation et performances	9
IV.2	Analyse de l'importance des variables	10
IV.3	Analyse géographique et temporelle	11
IV.4	Limites identifiées	11
V.	CONCLUSION	12
V.1	Synthèse des enseignements	12
V.2	Recommandations et pistes d'amélioration	12
V.3	Impact potentiel pour la STEG	13
	BIBLIOGRAPHIE / WEBOGRAPHIE	14

I. INTRODUCTION

I.1 Présentation de l'organisme

La Société Tunisienne de l'Électricité et du Gaz (STEG) est un établissement public à caractère non administratif, placé sous la tutelle du ministère de l'Énergie tunisien. Elle assume trois missions fondamentales : la production, le transport et la distribution de l'électricité et du gaz naturel sur l'ensemble du territoire tunisien. En tant qu'opérateur national de l'énergie, la STEG dessert plusieurs millions de clients répartis dans les zones urbaines, périurbaines et rurales du pays, faisant d'elle un acteur incontournable du développement socio-économique de la Tunisie.

I.2 Contexte et problématique

La STEG est confrontée à un problème structurel de fraude énergétique, qui se manifeste principalement par des manipulations illicites des compteurs d'électricité et de gaz. Ces pratiques frauduleuses génèrent des pertes financières considérables, estimées à environ 200 millions de dinars tunisiens, affectant directement la viabilité économique de l'entreprise et la qualité du service rendu à l'ensemble des abonnés légitimes.

Afin de lutter contre ce phénomène de manière systématique, la STEG a initié un partenariat avec la plateforme Zindi dans le cadre d'une compétition ouverte intitulée « Fraud Detection in Electricity and Gas Consumption Challenge ». L'objectif est de développer un système automatisé de détection des comportements frauduleux à partir de l'historique de facturation des clients. La performance des modèles est évaluée sur la base de l'aire sous la courbe ROC (AUC), métrique particulièrement adaptée aux problèmes de classification déséquilibrée (Zindi Africa, 2020).

I.3 Objectifs du projet

Ce projet de data science s'articule autour de cinq objectifs complémentaires : identifier le taux de clients frauduleux et caractériser leur profil ; analyser la distribution géographique de la fraude par région et district afin de cibler les zones à risque ; étudier les cohortes d'inscription les plus exposées au risque frauduleux ; construire un modèle prédictif performant fondé sur des techniques de gradient boosting ; et maximiser le score AUC sur le leaderboard public de la compétition Zindi.

II. PRÉSENTATION DES DONNÉES ET DU DATASET

II.1 Description des fichiers de données

Les données exploitées dans ce projet sont issues de la compétition officielle Zindi Africa (2020). Elles se composent de deux fichiers CSV complémentaires, dont les caractéristiques sont présentées dans le tableau ci-dessous. La variable cible est binaire : 1 désigne un client frauduleux, 0 un client légitime. Le jeu de données présente un déséquilibre significatif entre les deux classes (cf. Figure 1), avec environ 14,7 % de clients frauduleux, ce qui constitue un défi classique de classification déséquilibrée.

Fichier	Contenu	Rôle
client.csv	Liste annotée de clients avec localisation et catégorie	Variable cible (fraude / non fraude)
invoice.csv	Historique des factures de chaque client sur la durée d'observation	Variables prédictives

Tableau 1 : Description des fichiers de données — Compétition Zindi STEG




Figure 1 : Déséquilibre de classes — 14,7 % de clients frauduleux dans le dataset

II.2 Variables du dataset clients

Le fichier clients contient six variables essentielles à la modélisation : l'identifiant unique du client (client_id), le district de résidence, la catégorie du client (résidentielle, commerciale ou industrielle), la région géographique, la date d'inscription (creation_date) et la variable cible binaire (target). Le tableau ci-dessous en présente la description détaillée.

Variable	Type	Description
client_id	Identifiant	Clé unique d'identification du client
district	Catégorielle	District géographique de résidence
client_catg	Catégorielle	Catégorie : résidentielle, commerciale, industrielle
region	Catégorielle	Région géographique en Tunisie
creation_date	Date	Date d'inscription du client (cohorte)
target	Binaire	Variable cible : 1 = frauduleux, 0 = légitime

Tableau 2 : Variables du fichier clients (client.csv)

II.3 Variables du dataset factures

Le fichier factures (invoice.csv) regroupe l'ensemble des informations de facturation. Il contient notamment : l'identifiant client, la date de facture, le type de tarif, le numéro et statut du compteur, le code compteur, la remarque de relevé, le coefficient multiplicateur, les niveaux de consommation par tranche tarifaire (1 à 4), l'index ancien et nouveau du compteur, le nombre de mois de la période de facturation, ainsi que le type de compteur (électricité ou gaz). Ce fichier constitue la principale source de variables prédictives après agrégation temporelle par client.

III. DÉVELOPPEMENT

III.1 Analyse exploratoire des données (EDA)

L'analyse exploratoire a permis de mettre en évidence cinq caractéristiques structurantes du jeu de données, qui ont guidé les choix méthodologiques ultérieurs. Le déséquilibre de classes constitue le premier défi : le taux de fraude ($\approx 14,7\%$) est significativement inférieur au taux de clients légitimes, nécessitant un traitement spécifique lors de la modélisation. La distribution géographique hétérogène révèle que certaines régions et districts concentrent des taux de fraude nettement supérieurs à la moyenne nationale (cf. Figure 2), suggérant l'existence de zones à risque ciblables.

L'analyse des cohortes d'inscription (Figure 3) montre que certaines périodes sont associées à des taux de fraude significativement plus élevés, ouvrant la voie à des campagnes de vérification temporellement ciblées. Par ailleurs, plusieurs colonnes présentent des valeurs manquantes nécessitant un traitement préalable, et des patterns de consommation anormaux (index aberrants, coefficients suspects) ont été identifiés comme indicateurs potentiels de fraude.




Figure 2 : Distribution géographique du taux de fraude par région — Zones à risque en rouge ($>18\%$)




Figure 3 : Taux de fraude par cohorte d'inscription — Les clients anciens présentent un risque plus élevé

III.2 Préparation et prétraitement des données

La phase de prétraitement a constitué un préalable indispensable à la modélisation et s'est articulée autour de cinq axes principaux. Le nettoyage des données a consisté en la suppression ou l'imputation des valeurs manquantes selon la nature et la densité des informations disponibles. L'encodage des variables catégorielles a mobilisé le Label Encoding pour les variables ordinales et le One-Hot Encoding pour les variables nominales.

L'agrégation temporelle des factures par client a permis de calculer des statistiques descriptives (moyenne, somme, minimum, maximum de la consommation, nombre de factures) afin de synthétiser l'historique individuel de chaque abonné. L'ingénierie de variables (Feature Engineering) a ensuite produit de nouvelles variables explicatives : durée de présence dans le portefeuille, variations de consommation inter-périodes, et ratios d'index de compteur. Enfin, la gestion du déséquilibre a été assurée via le paramètre `scale_pos_weight` dans l'algorithme XGBoost (Chen & Guestrin, 2016).




Figure 4 : Pipeline de traitement des données — De la donnée brute au score AUC

III.3 Modèles testés et méthodes d'apprentissage

Cinq algorithmes de classification supervisée ont été évalués dans le cadre de ce projet. La Figure 5 compare leurs scores AUC respectifs. Chaque modèle a été entraîné sur les mêmes données prétraitées afin d'assurer une comparaison équitable. La métrique de référence est l'AUC (Area Under the ROC Curve), retenue par la compétition Zindi pour sa robustesse face au déséquilibre de classes.

Modèle	Avantages	Inconvénients
Régression Logistique	Simple, interprétable, rapide	Peu adapté aux relations non-linéaires complexes
Random Forest	Robuste au bruit, gère la multicollinéarité	Moins performant que le boosting sur ce type de données
XGBoost	Haute performance, gestion native du déséquilibre, régularisation intégrée	Hyperparamètres à configurer (Chen & Guestrin, 2016)
LightGBM	Très rapide, efficace sur grandes données	Moins stable que XGBoost sur petits datasets (Ke et al., 2017)
CatBoost	Gestion native des variables catégorielles, robuste	Temps d'entraînement plus long (Prokhorenkova et al., 2018)

Tableau 3 : Comparaison des algorithmes de classification supervisée testés




Figure 5 : Comparaison des scores AUC — XGBoost optimisé obtient le meilleur résultat (0,880)

III.4 Modèle retenu : XGBoost optimisé

Le classifieur XGBoost (eXtreme Gradient Boosting) a été sélectionné comme modèle principal en raison de ses performances supérieures sur les problèmes de détection de fraude à classes déséquilibrées (Chen & Guestrin, 2016). La configuration hyperparamétrique retenue est détaillée dans le tableau ci-dessous. Le nombre d'estimateurs fixé à 4 000 a été déterminé après analyse de la courbe d'évolution de l'AUC (Figure 6), qui montre une convergence stable à partir de ce seuil sans sur-apprentissage significatif.

Hyperparamètre	Valeur	Justification
n_estimators	4 000	Nombre d'arbres élevé pour maximiser la capacité d'apprentissage
learning_rate	0,01	Faible taux d'apprentissage pour une convergence stable et précise
max_depth	3	Profondeur limitée pour prévenir le sur-apprentissage
objective	binary:logistic	Adapté à la classification binaire (fraude / non fraude)
scale_pos_weight	ratio 0/1	Compensation du déséquilibre entre les deux classes
gamma	0,1	Pénalisation des divisions peu informatives
reg_lambda	1	Régularisation L2 pour réduire le sur-apprentissage

Tableau 4 : Configuration hyperparamétrique du modèle XGBoost retenu




Figure 6 : Évolution de l'AUC selon le nombre d'estimateurs — Convergence à $n=4\ 000$

La stratégie de validation adoptée est de type GroupKFold à six plis, en regroupant les observations par mois afin de simuler une validation temporelle réaliste. Cette approche permet d'évaluer la capacité du modèle à généraliser sur des données futures non observées lors de l'entraînement. Une évaluation distincte a été conduite sur les clients connus et sur les nouveaux clients, afin de mesurer la robustesse de la généralisation (cf. Figure 7).




Figure 7 : Résultats de la validation croisée GroupKFold (6 plis temporels) — AUC moyenne = 0,879

IV. RÉSULTATS ET DISCUSSION

IV.1 Métriques d'évaluation et performances

La métrique principale retenue par la compétition est l'AUC (Area Under the ROC Curve), qui mesure la capacité discriminante du modèle indépendamment du seuil de décision. La Figure 8 présente les courbes ROC comparatives de l'ensemble des modèles testés. Le tableau ci-dessous récapitule l'évolution des performances au fil des itérations méthodologiques, depuis le point de référence initial jusqu'au modèle optimisé.

Approche de modélisation	AUC public	Remarques
Baseline LightGBM (variables brutes)	0,844	Point de départ de référence minimal
XGBoost + feature engineering de base	≈ 0,86	Amélioration grâce à l'agrégation temporelle
XGBoost optimisé (4 000 estimateurs)	≈ 0,88	Meilleur compromis biais/variance obtenu
Ensemble stacking/blending (piste future)	> 0,90 (estimé)	Piste d'amélioration non encore explorée

Tableau 5 : Récapitulatif des performances obtenues — Score AUC public (Zindi)




Figure 8 : Courbes ROC comparatives — Le modèle XGBoost optimisé (vert) domine sur l'ensemble du spectre

IV.2 Analyse de l'importance des variables

L'analyse de l'importance des variables (feature importance) réalisée à partir du modèle XGBoost entraîné a mis en évidence une hiérarchie claire entre les différents types de variables (Figure 9). Les agrégations de consommation par client (moyenne, variance, tendance temporelle) et les statistiques sur les index de compteur (delta d'index, anomalies de lecture) constituent les variables les plus discriminantes pour la détection de fraude, avec un gain normalisé supérieur à 0,13 pour chacune.

Cette observation confirme l'importance centrale du feature engineering : la valeur prédictive de ce projet repose davantage sur la qualité des variables construites que sur le choix de l'algorithme lui-même. Les variables géographiques (district et région) et contextuelles (type de compteur, catégorie client) contribuent également mais dans une moindre mesure. Ce résultat est cohérent avec les travaux de Chawla et al. (2002) sur la représentation des données dans les problèmes à classes déséquilibrées.




Figure 9 : Importance des variables — Les agrégations de consommation (vert) sont les plus discriminantes

IV.3 Analyse géographique et temporelle

L'analyse exploratoire géographique a révélé une distribution non uniforme de la fraude sur le territoire tunisien. Les régions de Gafsa (24,5 %) et Gabès (22,1 %) concentrent un nombre disproportionné de clients frauduleux, ce qui suggère l'existence de facteurs socio-économiques locaux ou des difficultés spécifiques de contrôle terrain dans ces zones. Ces résultats plaident en faveur d'une stratégie de contrôle priorisée géographiquement.

Sur le plan temporel, certaines cohortes de clients — définies par leur date d'inscription — présentent des taux de fraude significativement plus élevés que la moyenne. L'analyse montre une corrélation négative entre l'ancienneté d'inscription et le taux de fraude : les clients inscrits avant 2010 affichent des taux supérieurs à 18 %, contre moins de 10 % pour les cohortes récentes (2019-2021). Cette observation ouvre la voie à des campagnes de vérification ciblées sur certaines générations d'abonnés.

IV.4 Limites identifiées

Plusieurs limites méritent d'être signalées dans une perspective d'amélioration continue. Premièrement, l'absence d'optimisation systématique des hyperparamètres : aucune recherche formelle par grille (GridSearch) ou par optimisation bayésienne (Optuna) n'a été conduite, ce qui laisse envisager un potentiel d'amélioration non exploité. Deuxièmement, le risque de multicolinéarité entre certaines variables agrégées pourrait affecter la stabilité des estimations du modèle XGBoost. Troisièmement, la richesse limitée des features contextuelles (absence d'historique d'inspections terrain, de données de plaintes, de variables environnementales) contraint le pouvoir explicatif des variables disponibles.

V. CONCLUSION

V.1 Synthèse des enseignements

Ce projet démontre que la détection automatisée de fraude dans la consommation d'énergie constitue un problème de classification déséquilibrée pour lequel les approches par gradient boosting — en particulier l'algorithme XGBoost (Chen & Guestrin, 2016) — s'avèrent particulièrement performantes avec un score AUC de 0,88 sur le leaderboard public Zindi. Quatre enseignements principaux se dégagent de ce travail.

En premier lieu, l'ingénierie de variables (feature engineering) constitue le levier d'amélioration le plus déterminant, davantage que le choix de l'algorithme lui-même. En second lieu, l'agrégation temporelle des historiques de facturation par client permet de capturer des comportements anormaux que les modèles appliqués sur des données brutes seraient incapables de détecter. En troisième lieu, la gestion explicite du déséquilibre de classes via le paramètre `scale_pos_weight` est indispensable pour éviter que le modèle ne privilégie systématiquement la classe majoritaire. Enfin, la validation croisée temporelle (GroupKFold par mois) est essentielle pour obtenir une estimation réaliste des performances généralisables à des données futures.

V.2 Recommandations et pistes d'amélioration

Au terme de cette étude, plusieurs recommandations sont formulées afin de consolider et d'étendre les résultats obtenus. L'optimisation des hyperparamètres via Optuna ou une recherche par grille permettrait de maximiser davantage l'AUC et de réduire la sensibilité du modèle à la configuration initiale. L'exploration des techniques d'ensemble (stacking, blending) combinant XGBoost, LightGBM (Ke et al., 2017) et CatBoost (Prokhorenkova et al., 2018) est susceptible d'apporter un gain de performance supplémentaire estimé au-delà de 0,90 d'AUC.

Par ailleurs, l'enrichissement des données avec des variables contextuelles (localisation GPS des compteurs, historique d'inspections terrain, données météorologiques corrélées à la consommation) renforcerait significativement le pouvoir prédictif du modèle. La mise en place d'un système de monitoring en production pour surveiller la dérive des données (data drift) et déclencher un réentraînement périodique constitue également une priorité opérationnelle. Enfin, le développement d'un tableau de bord permettant aux équipes terrain de la STEG de prioriser leurs contrôles selon le score de risque individuel de chaque client représente l'aboutissement naturel de ce projet.

V.3 Impact potentiel pour la STEG

L'implémentation d'un système de détection automatisée performant représente un enjeu stratégique et financier majeur pour la STEG. En ciblant efficacement les contrôles terrain sur les clients à haut risque de fraude, l'entreprise pourrait réduire significativement ses pertes financières, estimées à 200 millions de dinars tunisiens (Zindi Africa, 2020). Chaque point de pourcentage supplémentaire d'AUC se traduit directement par une meilleure identification des fraudeurs et une réduction du nombre de faux positifs, c'est-à-dire de contrôles inutiles menés sur des clients légitimes. Ce double bénéfice — économique et opérationnel — justifie pleinement l'investissement consenti dans le développement d'un tel système de détection par apprentissage automatique.

BIBLIOGRAPHIE / WEBOGRAPHIE

- [1] Zindi Africa. (2020). Fraud Detection in Electricity and Gas Consumption Challenge. Récupéré sur : <https://zindi.africa/competitions/fraud-detection-in-electricity-and-gas-consumption-challenge>
- [2] Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. doi:10.1145/2939672.2939785
- [3] Ke, G., et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. Advances in Neural Information Processing Systems (NeurIPS).
- [4] Prokhorenkova, L., et al. (2018). CatBoost: unbiased boosting with categorical features. NeurIPS.
- [5] Chawla, N.V., et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research, 16, 321–357.