Université Hassan 1er

ÉCOLE NATIONALE DE COMMERCE ET DE GESTION DE SETTAT

COMPTE RENDU DE PROJET — S8

Détection de Fraude dans la Consommation d'Énergie

Compétition Zindi — STEG (Société Tunisienne de l'Électricité et du Gaz)

Module :	Machine Learning & Data Science
Filière :	CAC / Commerce International / PSCM — L3 S8
Réalisé par :	Siham MAHBOUB et Marwa LIOUSFI
Encadrant :	abderrahim larhlimi
Année Universitaire :	2026–2027

Année Universitaire 2026–2027

SOMMAIRE

I. Introduction 3

I.1 Présentation de l'organisme 3

I.2 Problématique et contexte 3

I.3 Objectifs du projet 3

II. Développement 4

II.1 Présentation et description des données 4

II.2 Analyse exploratoire des données (EDA) 5

II.3 Préparation et prétraitement des données 5

II.4 Modèles testés et comparaison 6

II.5 Modèle retenu : XGBoost 7

III. Résultats et Discussion 8

III.1 Métriques d'évaluation et performances 8

III.2 Analyse de l'importance des variables 8

III.3 Analyse géographique et temporelle 9

III.4 Limites identifiées 9

IV. Conclusion 10

IV.1 Synthèse des enseignements 10

IV.2 Recommandations et pistes d'amélioration 10

IV.3 Impact potentiel pour la STEG 10

Bibliographie / Webographie 11

I. INTRODUCTION

I.1 Présentation de l'organisme d'accueil

La Société Tunisienne de l'Électricité et du Gaz (STEG) est un établissement public à caractère non administratif, placé sous la tutelle du ministère de l'Énergie tunisien. Elle assume trois missions fondamentales : la production, le transport et la distribution de l'électricité et du gaz naturel sur l'ensemble du territoire tunisien. En tant qu'opérateur national de l'énergie, la STEG dessert plusieurs millions de clients répartis dans les zones urbaines, périurbaines et rurales du pays, faisant d'elle un acteur incontournable du développement socio-économique de la Tunisie.

I.2 Contexte et problématique

La STEG est confrontée à un problème structurel de fraude énergétique, qui se manifeste principalement par des manipulations illicites des compteurs d'électricité et de gaz. Ces pratiques frauduleuses génèrent des pertes financières considérables, estimées à environ 200 millions de dinars tunisiens, affectant directement la viabilité économique de l'entreprise et la qualité du service rendu à l'ensemble des abonnés légitimes.

Afin de lutter contre ce phénomène de manière systématique, la STEG a initié un partenariat avec la plateforme Zindi dans le cadre d'une compétition ouverte intitulée « Fraud Detection in Electricity and Gas Consumption Challenge ». L'objectif de cette compétition est de développer un système automatisé de détection des comportements frauduleux à partir de l'historique de facturation des clients. La performance des modèles soumis est évaluée sur la base de l'aire sous la courbe ROC (AUC), métrique particulièrement adaptée aux problèmes de classification déséquilibrée.

I.3 Objectifs du projet

Ce projet de data science s'articule autour de cinq objectifs complémentaires :

- Identifier le taux de clients frauduleux dans le jeu de données fourni et caractériser leur profil ;

- Analyser la distribution géographique de la fraude par région et par district afin de cibler les zones à risque ;
- Étudier les cohortes d'inscription les plus exposées au risque frauduleux selon une perspective temporelle ;
- Construire un modèle prédictif performant, fondé sur des techniques de gradient boosting, pour automatiser la détection ;
- Maximiser le score AUC sur le leaderboard public de la compétition Zindi.

II. DÉVELOPPEMENT

II.1 Présentation et description des données

Les données exploitées dans ce projet sont issues de la compétition officielle Zindi. Elles se composent de deux fichiers CSV complémentaires, dont les caractéristiques sont présentées dans le tableau ci-dessous.

Tableau 1 : Description des fichiers de données

Fichier	Contenu	Rôle
client.csv	Liste annotée de clients avec leur localisation et leur catégorie	Variable cible (fraude / non fraude)
invoice.csv	Historique des factures de chaque client sur la durée d'observation	Variables prédictives

II.1.1 Variables du fichier clients

Le fichier clients contient six variables : l'identifiant unique du client (client_id), le district de résidence, la catégorie du client (résidentielle, commerciale ou industrielle), la région géographique, la date d'inscription (creation_date) et la variable cible binaire (target : 1 = frauduleux, 0 = légitime).

II.1.2 Variables du fichier factures

Le fichier factures regroupe l'ensemble des informations de facturation : identifiant client, date de facture, type de tarif, numéro et statut du compteur, code compteur, remarque de relevé, coefficient multiplicateur, niveaux de consommation par tranche tarifaire (1 à 4), index ancien et nouveau du compteur, nombre de mois de la période de facturation, ainsi que le type de compteur (électricité ou gaz).

II.2 Analyse exploratoire des données (EDA)

L'analyse exploratoire a permis de mettre en évidence cinq caractéristiques structurantes du jeu de données, qui ont guidé les choix méthodologiques ultérieurs :

- **Déséquilibre de classes : le taux de fraude est significativement inférieur au taux de clients légitimes, ce qui constitue un défi classique de classification déséquilibrée nécessitant un traitement spécifique.**

- Distribution géographique hétérogène : certaines régions et certains districts concentrent des taux de fraude nettement plus élevés que la moyenne nationale, suggérant l'existence de zones géographiques à risque.
- Effets de cohorte : l'analyse temporelle révèle que certaines périodes d'inscription sont associées à des taux de fraude significativement supérieurs à d'autres.
- Données manquantes : plusieurs colonnes présentent des valeurs absentes nécessitant un traitement préalable à la modélisation.
- Patterns de consommation anormaux : des comportements atypiques ont été identifiés (index aberrants, coefficients suspects), constituant des indicateurs potentiels de fraude.

II.3 Préparation et prétraitement des données

La phase de prétraitement a constitué un préalable indispensable à la modélisation. Elle s'est articulée autour de cinq axes principaux :

- Nettoyage des données : suppression ou imputation des valeurs manquantes selon la nature et la densité des informations disponibles ;
- Encodage des variables catégorielles : recours au Label Encoding pour les variables ordinales et au One-Hot Encoding pour les variables nominales ;
- Agrégation temporelle des factures : calcul de statistiques descriptives par client (moyenne, somme, minimum, maximum de la consommation, nombre de factures, etc.) afin de synthétiser l'historique individuel ;
- **Ingénierie de variables (Feature Engineering) : création de nouvelles variables explicatives telles que la durée de présence dans le portefeuille, les variations de consommation inter-périodes et les ratios d'index de compteur ;**
- Gestion du déséquilibre : mobilisation du paramètre scale_pos_weight dans l'algorithme XGBoost pour équilibrer la contribution des deux classes lors de l'apprentissage.

II.4 Modèles testés et comparaison

Cinq algorithmes de classification ont été évalués dans le cadre de ce projet. Le tableau ci-après en présente une synthèse comparative.

Tableau 2 : Comparaison des algorithmes de classification testés

Modèle	Avantages	Inconvénients
Régression Logistique	Simple, interprétable, rapide à entraîner	Peu adapté aux relations non-linéaires complexes
Random Forest	Robuste au bruit, gère la multicolinéarité	Moins performant que le boosting sur ce type de données
XGBoost	Haute performance, gestion native du déséquilibre, régularisation intégrée	Sensible à la multicolinéarité, hyperparamètres à configurer
LightGBM	Très rapide, efficace sur grandes données, bonne AUC	Moins stable que XGBoost sur de petits jeux de données
CatBoost	Gestion native des variables catégorielles, robuste	Temps d'entraînement plus long

II.5 Modèle retenu : XGBoost

Le classifieur XGBoost (eXtreme Gradient Boosting) a été sélectionné comme modèle principal en raison de ses performances supérieures sur les problèmes de détection de fraude à classes déséquilibrées. La configuration hyperparamétrique retenue est détaillée dans le tableau suivant.

Tableau 3 : Configuration hyperparamétrique du modèle XGBoost

Hyperparamètre	Valeur	Justification
n_estimators	4 000	Nombre d'arbres élevé pour maximiser la capacité d'apprentissage
learning_rate	0,01	Faible taux d'apprentissage pour une convergence stable et précise
max_depth	3	Profondeur limitée pour prévenir le sur-apprentissage
objective	binary:logistic	Adapté à la classification binaire (fraude / non fraude)
scale_pos_weight	ratio 0/1	Compensation du déséquilibre entre les deux classes
gamma	0,1	Pénalisation des divisions peu informatives
reg_lambda	1	Régularisation L2 pour réduire le sur-apprentissage

La stratégie de validation adoptée est de type GroupKFold à six plis, en regroupant les observations par mois afin de simuler une validation temporelle réaliste. Cette approche

permet d'évaluer la capacité du modèle à généraliser sur des données futures non observées lors de l'entraînement. Une évaluation distincte a été conduite sur les clients connus (déjà présents dans le jeu d'entraînement) et sur les nouveaux clients, afin de mesurer la robustesse de la généralisation.

III. RÉSULTATS ET DISCUSSION

III.1 Métriques d'évaluation et performances

La métrique principale retenue par la compétition est l'AUC (Area Under the ROC Curve), qui mesure la capacité discriminante du modèle indépendamment du seuil de décision. Des métriques complémentaires ont également été calculées pour enrichir l'analyse.

Tableau 4 : Récapitulatif des performances obtenues

Approche de modélisation	Score AUC public	Remarques
Baseline LightGBM (variables brutes uniquement)	0,844	Point de départ de référence minimal
XGBoost avec feature engineering de base	~0,86	Amélioration significative grâce à l'agrégation temporelle
XGBoost optimisé (4 000 estimateurs)	~0,88	Meilleur compromis biais/variance obtenu
Ensemble (stacking/blending) — piste future	> 0,90 (estimé)	Piste d'amélioration non encore explorée

III.2 Analyse de l'importance des variables

L'analyse de l'importance des variables (feature importance) réalisée à partir du modèle XGBoost entraîné a mis en évidence une hiérarchie claire entre les différents types de variables. Les agrégations de consommation par client (moyenne, variance, tendance temporelle) et les statistiques sur les index de compteur (delta d'index, anomalies de lecture) constituent les variables les plus discriminantes pour la détection de fraude. Les variables temporelles (ancienneté du client, saisonnalité), le type de compteur, la catégorie du client ainsi que les variables géographiques (district et région) contribuent également à la performance prédictive, mais dans une moindre mesure.

Cette observation confirme l'importance centrale du feature engineering : la valeur prédictive de ce projet repose davantage sur la qualité des variables construites que sur le choix de l'algorithme lui-même.

III.3 Analyse géographique et temporelle

L'analyse exploratoire géographique a révélé une distribution non uniforme de la fraude sur le territoire tunisien. Certaines régions concentrent un nombre disproportionné de clients frauduleux, ce qui suggère l'existence de facteurs socio-économiques locaux ou des difficultés spécifiques de contrôle terrain dans ces zones. Ces résultats plaident en faveur d'une stratégie de contrôle priorisée géographiquement.

Sur le plan temporel, certaines cohortes de clients — définies par leur date d'inscription — présentent des taux de fraude significativement plus élevés que la moyenne. Cette observation ouvre la voie à des campagnes de vérification ciblées sur certaines générations d'abonnés.

III.4 Limites identifiées

Plusieurs limites méritent d'être signalées dans une perspective d'amélioration continue :

- Absence d'optimisation systématique des hyperparamètres : aucune recherche formelle par grille (GridSearch) ou par optimisation bayésienne (Optuna) n'a été conduite, ce qui laisse envisager un potentiel d'amélioration non exploité ;
- Risque de multicolinéarité : des corrélations élevées entre certaines variables agrégées pourraient affecter la stabilité des estimations du modèle XGBoost ;
- Richesse limitée des features contextuelles : l'absence d'informations complémentaires (historique d'inspections terrain, données de plaintes, variables environnementales) contraint le pouvoir explicatif des variables disponibles.

IV. CONCLUSION

IV.1 Synthèse des enseignements

Ce projet démontre que la détection automatisée de fraude dans la consommation d'énergie constitue un problème de classification déséquilibrée pour lequel les approches par gradient boosting — en particulier l'algorithme XGBoost — s'avèrent particulièrement performantes. Quatre enseignements principaux se dégagent de ce travail :

- **L'ingénierie de variables (feature engineering) constitue le levier d'amélioration le plus déterminant, davantage que le choix de l'algorithme lui-même.**
- L'agrégation temporelle des historiques de facturation par client permet de capturer des comportements anormaux que les modèles appliqués sur des données brutes seraient incapables de détecter.
- La gestion explicite du déséquilibre de classes (via le paramètre scale_pos_weight) est indispensable pour éviter que le modèle ne privilégie systématiquement la classe majoritaire.
- La validation croisée temporelle (GroupKFold par mois) est essentielle pour obtenir une estimation réaliste des performances généralisables à des données futures.

IV.2 Recommandations et pistes d'amélioration

Au terme de cette étude, plusieurs recommandations sont formulées afin de consolider et d'étendre les résultats obtenus :

- **Optimisation des hyperparamètres via Optuna ou une recherche par grille, afin de maximiser davantage l'AUC et de réduire la sensibilité du modèle à la configuration initiale.**
- **Exploration des techniques d'ensemble (stacking, blending) combinant XGBoost, LightGBM et CatBoost, susceptibles d'apporter un gain de performance supplémentaire.**

- Enrichissement des données avec des variables contextuelles : localisation GPS des compteurs, historique d'inspections terrain, données météorologiques corrélées à la consommation.
- Mise en place d'un système de monitoring en production pour surveiller la dérive des données (data drift) et déclencher un réentraînement périodique du modèle.
- Développement d'un tableau de bord opérationnel permettant aux équipes terrain de la STEG de prioriser leurs contrôles selon le score de risque individuel de chaque client.

IV.3 Impact potentiel pour la STEG

L'implémentation d'un système de détection automatisée performant représente un enjeu stratégique et financier majeur pour la STEG. En ciblant efficacement les contrôles terrain sur les clients à haut risque de fraude, l'entreprise pourrait réduire significativement ses pertes financières, estimées à 200 millions de dinars tunisiens. Par ailleurs, chaque point de pourcentage supplémentaire d'AUC se traduit directement par une meilleure identification des fraudeurs et une réduction du nombre de faux positifs, c'est-à-dire de contrôles inutiles menés sur des clients légitimes. Ce double bénéfice — économique et opérationnel — justifie pleinement l'investissement consenti dans le développement d'un tel système.

BIBLIOGRAPHIE / WEBOGRAPHIE

Zindi Africa. (2020). Fraud Detection in Electricity and Gas Consumption Challenge. Récupéré sur : https://zindi.africa/competitions/fraud-detection-in-electricity-and-gas-consumption-challenge

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. doi:10.1145/2939672.2939785

Ke, G., et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. Advances in Neural Information Processing Systems (NeurIPS).

Prokhorenkova, L., et al. (2018). CatBoost: unbiased boosting with categorical features. NeurIPS.

Chawla, N.V., et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research, 16, 321-357.